

Régression linéaire multiple

- Fondements et interprétation géométrique
- Estimation
- Loi des estimateurs
- Pratique en R
- Sélection de modèles

Généralités sur la régression

- Comment exprimer le fait que Y dépende de X à travers son espérance ?
- $E[Y|X=x]=f(X)$
- Si on note $\varepsilon=Y-E[Y|X=x]$
(« erreur » supposée indépendante de X), alors $E[\varepsilon]=0$
- Du coup, $var(\varepsilon)=var(Y|X=x)=\sigma^2$ notation
à supposer que $var(Y)$ existe.
- Synthèse : $Y=f(X)+\varepsilon$ où $E[\varepsilon]=0$ et $var(\varepsilon)=\sigma^2$
- Même en admettant que ce modèle soit pertinent, comment trouver f ?

Approximation de Y par $f(X)$

- $E[Y|X]$ est la meilleure approximation de Y par une fonction $f(X)$:
 - au sens de la distance² $E[(A-B)^2]$
 - pour les fonctions f telles que $E[(Y-f(X))^2]$ existe
 - ($\Leftrightarrow E[f(X)^2]$ existe $\Leftrightarrow \text{var}[f(X)^2]$ existe)
- Rappel : $E[Y|X=x]$ est une certaine fonction $f(x)$
 $E[Y|X]$ est $f(X)$ (variable aléatoire)
- Comment trouver f ?
 - chercher dans une famille de fonctions, par exemple fonctions affines de X .

Interprétation cas X déterministe

Réécrire le résultat précédent dans le cas où X est déterministe.

- Interprétez ce résultat. Le connaissiez-vous déjà ? Faire un lien avec $\text{var}(Y)$
- À faire par groupes de deux étudiants. Durée : 3 min

Propriété de $E[Y|X]$: décomposition de $\text{var}(Y)$

- Montrer que

$$\underbrace{E[(Y - E[Y])^2]}_{\text{var}(Y)} = \underbrace{E[(Y - E[Y|X])^2]}_{E[\text{var}(Y|X)]} + \underbrace{E[(E[Y|X] - E[Y])^2]}_{\text{var}(E[Y|X])}$$

- Interpréter le résultat en prenant :
 - X et Y indépendants
 - $Y = f(X)$
 - $Y = \underbrace{f(X)}_{\text{indépendants}} + \varepsilon$

Interprétation : décomposition de la variance

- Que donne $\text{var}(Y) = E[\text{var}(Y|X)] + \text{var}(E[Y|X])$?
 - pour X et Y indépendants :
 - pour $Y = f(X)$
 - pour

Fondements probabilistes de la régression multiple

- Les résultats précédents se généralisent à l'approximation de Y par $f(X_1, \dots, X_p)$


$$Y = f(X_1, \dots, X_p) + \varepsilon \quad \text{où} \quad E[\varepsilon] = 0 \quad \text{et} \quad \text{var}(\varepsilon) = \sigma^2$$


- Une fois de plus, meilleure approximation de Y par une fonction $f(X_1, \dots, X_p)$ de variance finie :

$$\operatorname{argmin}_{f(X_1, \dots, X_p)} E[(Y - f(X_1, \dots, X_p))^2] = E[Y | X_1, \dots, X_p]$$

Régression linéaire simple

- Je dispose des données suivantes :



Est-ce que $E[Y|X=x]$ vaut $ax+b$?

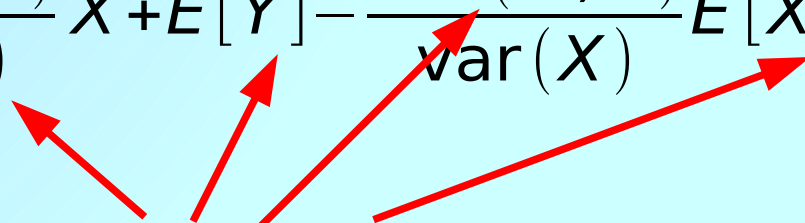
Que signifie $Y = \beta_1 x + \beta_0 + \varepsilon$?

- À comprendre comme :

« je choisis d'approximer Y par une fonction affine de x »
qui est un plan de l'espace des fonctions de x .

Je vais donc chercher la meilleure fonction affine de X qui approxime Y :

en principe c'est

$$\frac{\text{cov}(X, Y)}{\text{var}(X)} X + E[Y] - \frac{\text{cov}(X, Y)}{\text{var}(X)} E[X]$$


mais on ne connaît pas la loi de (X, Y)

- En pratique : on va estimer β_1 et β_0 à partir d'un échantillon $(x_i, y_i)_{i=1, \dots, n}$

Régression linéaire multiple

- Modèle statistique de régression linéaire multiple :

$$Y_i = \beta_p x_{p,i} + \dots + \beta_1 x_{1,i} + \beta_0 + \varepsilon_i \quad \text{où } E[\varepsilon_i] = 0 \text{ et } \text{var}(\varepsilon_i) = \sigma^2$$

- Modèle paramétrique à $p+2$ paramètres $\beta_p, \dots, \beta_1, \beta_0$ et σ^2 à estimer à partir de n observations y_i et régresseurs $x_{p,i}, \dots, x_{1,i}$ (approche statistique)
- Notations :

$$Y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} \quad \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix} \quad \beta = \begin{pmatrix} \beta_0 \\ \vdots \\ \beta_{p+1} \end{pmatrix} \quad X = \begin{pmatrix} 1 & x_{1,1} & \cdots & x_{p,1} \\ \vdots & \vdots & \vdots & \vdots \\ 1 & x_{1,n} & \cdots & x_{p,n} \end{pmatrix}$$


$$\Rightarrow Y = X\beta + \varepsilon$$

Interprétation géométrique

- On essaie d'ajuster un hyperplan à un nuage de points dans \mathbb{R}^{p+1}

– Ici pour $p=2$:

ε écart entre
l'observation et
l'hyperplan (espérance
conditionnelle)
dispersion de cet écart
caractérisée par σ^2



Estimation par moindres carrés pour β

- En l'absence d'hypothèse sur la loi des résidus (autre que sur leur espérance et variance-covariance)
- Minimisation de la moyenne des écarts entre les données y_i et l'hyperplan affine d'équation

$$\{y = \beta_p x_p + \dots + \beta_1 x_1 + \beta_0 \mid (y, x_1, \dots, x_p) \in \mathbb{R}^{p+1}\}$$

$$\hat{\beta} = \arg \min_{\beta \in \mathbb{R}^{p+1}} \frac{1}{n} \|Y - X\beta\|^2$$

- $X\hat{\beta} = \Pi_{E_X}(Y)$ où $E_X = \{X\beta \mid \beta \in \mathbb{R}^{p+1}\}$; Π_{E_X} projection orthogonale sur E_X
- Écrire que $Y - \Pi_{E_X}(Y)$ est orthogonal à tout élément de E_X .
- En déduire ${}^t X Y = {}^t X X \hat{\beta}$.
- En expliciter toutes les conséquences sur l'estimation de β .
 - À faire par groupes de deux étudiants. Durée : 10 min


Estimation de la variance

- Idée intuitive :

$$\varepsilon_i \approx \hat{\varepsilon}_i = Y_i - \underbrace{\hat{B}_p x_{pi} - \dots - \hat{B}_1 x_{1i} - \hat{B}_0}_{(X\hat{B})_i = \hat{Y}_i} \quad \text{donc} \quad \text{var}(\varepsilon_i) = \sigma^2 \approx \text{var}(\hat{\varepsilon}_i)$$

- On estime σ^2 par la variance empirique des résidus empiriques, notée $S_{Y|X}^2$ (variance résiduelle)

$$\begin{aligned} S_{Y|X}^2 &= \frac{1}{n} \|Y - X\hat{B}\|^2 \\ &= \frac{1}{n} \|\hat{\varepsilon}\|^2 \end{aligned}$$



«Débiaisage» de l'estimateur de σ^2

- $S_{Y|X}^2 = \frac{1}{n} \|Y - X\hat{B}\|^2$ est un estimateur biaisé de σ^2
- Propriété : $E[{}^tY A Y] = \text{tr}(A \text{cov}(Y)) + {}^tE[Y] A E[Y]$
- $E[\|Y - X\hat{B}\|^2] = E[\|\Pi_{E_X^\perp} Y\|^2] = \sigma^2 \text{tr}(\Pi_{E_X^\perp}) + {}^tE[Y] \Pi_{E_X^\perp} \underbrace{E[Y]}_{\in E_X}$
- donc $\hat{\sigma}^2 = \frac{1}{n - (p+1)} \|Y - X\hat{B}\|^2$ est un estimateur sans biais de σ^2
- Résultat de nature essentiellement géométrique
- Remarquer que $p+1$ est la dimension de β

« Rappels » : vecteurs gaussiens

- Loi normale multivariée $\mathcal{N}(\mu, \Sigma)$
- ???

Hypothèse gaussienne sur la loi de ε

- ε est un *vecteur gaussien*

$\Rightarrow Y = X\beta + \varepsilon$ est également un vecteur gaussien

$$\mathcal{N}_n(X\beta, \sigma^2 I_n)$$

- On obtient la loi des estimateurs.

En particulier : $\hat{B} \sim \mathcal{N}_{p+1}(\beta, \sigma^2 ({}^t X X)^{-1})$

- Possibilité de faire des intervalles de confiance, tests, validation du modèle

Interpréter les sorties de R

Call:

`lm(formula = y ~ x1 + x2 + x3 + x4)`

commande / formule
définissant le modèle et les
données

Ici : $Y = \beta_1 X_1 + \dots + \beta_4 X_4 + \beta_0 + \varepsilon$

Residuals:

Min	1Q	Median	3Q	Max
-1092.9	-263.2	-130.2	197.3	1883.1

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	52317.831	12237.362	4.275	0.00523	**
x1	27.641	5.429	5.091	0.00224	**
x2	12529.768	400.067	31.319	7.04e-08	***
x3	2553.211	530.669	4.811	0.00297	**
x4	-234.237	13.268	-17.654	2.12e-06	***

Residual standard error: 970.6 on 6 degrees of freedom

Multiple R-Squared: 0.9967, Adjusted R-squared: 0.9946

F-statistic: 459.8 on 4 and 6 DF, p-value: 1.372e-07

Régression linéaire multiple : estimation

Interpréter les sorties de R

Call:

```
lm(formula = y ~ x1 + x2 + x3 + x4)
```

Residuals:

Min	1Q	Median	3Q	Max
-1092.9	-263.2	-130.2	197.3	1883.1

Résidus empiriques : statistique descriptive (médiane et quartiles empiriques)

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	52317.831	12237.362	4.275	0.00523	**
x1	27.641	5.429	5.091	0.00224	**
x2	12529.768	400.067	31.319	7.04e-08	***
x3	2553.211	530.669	4.811	0.00297	**
x4	-234.237	13.268	-17.654	2.12e-06	***

Residual standard error: 970.6 on 6 degrees of freedom

Multiple R-Squared: 0.9967, Adjusted R-squared: 0.9946

F-statistic: 459.8 on 4 and 6 DF, p-value: 1.372e-07

Régression linéaire multiple : estimation

Quid de la moyenne empirique des résidus ?

- Pourquoi n'est-elle pas indiquée dans R ?
- À $\frac{1}{n}$ près c'est $\left\langle \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}; \Pi_{E_X^\perp} Y \right\rangle$
- En général, $\begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} \in E_X$ (c'est la 1^{ère} colonne de X)
- Les résidus empiriques sont de moyenne empirique nulle par construction !

Interpréter les sorties de R

Call:

```
lm(formula = y ~ x1 + x2 + x3 + x4)
```

Residuals:

Min	1Q	Median	3Q	Max
-1092.9	-263.2	-130.2	197.3	1883.1

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	52317.831	12237.362	4.275	0.00523	**
x1	27.641	5.429	5.091	0.00224	**
x2	12529.768	400.067	31.319	7.04e-08	***
x3	2553.211	530.669	4.811	0.00297	**
x4	-234.237	13.268	-17.654	2.12e-06	***

Pour chaque régresseur :
estimation, estimation de l'écart-type de sa loi, statistique de test de nullité et p-valeur de ce test

Residual standard error: 970.6 on 6 degrees of freedom

Multiple R-Squared: 0.9967, Adjusted R-squared: 0.9946

F-statistic: 459.8 on 4 and 6 DF, p-value: 1.372e-07

Régression linéaire multiple : estimation

Interpréter les sorties de R

Call:

```
lm(formula = y ~ x1 + x2 + x3 + x4)
```

Residuals:

Min	1Q	Median	3Q	Max
-1092.9	-263.2	-130.2	197.3	1883.1

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	52317.831	12237.362	4.275	0.00523	**
x1	27.641	5.429	5.091	0.00224	**
x2	12529.768	400.067	31.319	7.04e-08	***
x3	2553.211	530.669	4.811	0.00297	**
x4	-234.237	13.268	-17.654	2.12e-06	***

le lien n'est pas évident !

Residual standard error: 970.6 on 6 degrees of freedom

Multiple R-Squared: 0.9967, Adjusted R-squared: 0.9946

F-statistic: 459.8 on 4 and 6 DF, p-value: 1.372e-07

p-valeur du test de pertinence globale (prochain cours)

Régression linéaire multiple : estimation

R : cas particulier de prédicteurs qualitatifs

```
> myVar = factor(myVar)
```

Call:

```
lm(formula = y ~ myVar + x)
```

Residuals:

Min	1Q	Median	3Q	Max
-1092.9	-263.2	-130.2	197.3	1883.1

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	52317.831	12237.362	4.275	0.00523 **
myVar2	2.641	235.429	55.09	0.9224
myVar3	12529.768	400.067	31.319	7.04e-08 ***
x	-234.237	13.268	-17.654	2.12e-06 ***

Residual standard error: 970.6 on 6 degrees of freedom

Multiple R-Squared: 0.9967, Adjusted R-squared: 0.9946

F-statistic: 459.8 on 4 ...

→ Transforme myVar en variable catégorielle : modalités 1, 2, 3

Modèle $Y_i = \mu_{myVar_i} + \beta X_i + \varepsilon_i$

réécrit $Y_i = \beta_0 + v_{myVar_i} + \beta X_i + \varepsilon_i$

avec $myVar_i \neq 1; v_1 = 0$
voir ANOVA pour les explications

→ pas de ligne myVar1 :

$$\hat{\mu}_1 = \hat{\beta}_0; v_1 = 0$$

→ ligne myVar3 : \hat{v}_3

$$\hat{\mu}_3 = \hat{\beta}_0 + \hat{v}_3$$

→ ligne x : $\hat{\beta}$
(pas de subtilité)

Indépendance de \hat{B}^2 et $\hat{\sigma}^2$

- Découle du fait que $X\hat{B} = \Pi_{E_X} Y$ et $Y - X\hat{B} = \Pi_{E_X^\perp} Y$
- Si U est un vecteur gaussien $\mathcal{N}(0, \sigma^2 I)$ et Π un projecteur orthogonal, la matrice de covariance de $\begin{pmatrix} \Pi U \\ (I - \Pi)U \end{pmatrix}$ est $\begin{bmatrix} \Pi^t \Pi & \Pi^t (I - \Pi) \\ (I - \Pi)^t \Pi & (I - \Pi)^t (I - \Pi) \end{bmatrix} = \begin{bmatrix} \Pi & 0 \\ 0 & I - \Pi \end{bmatrix}$ donc ΠU et $U - \Pi U$ sont non-corrélés, d'où indépendants
- Voir que $\hat{B} = [(^t X X)^{-1} ^t X] X \hat{B}$: indépendant de $\frac{\|Y - X\hat{B}\|^2}{n - p - 1}$
- Indépendance essentielle pour construire des intervalles de confiance pour les β_i

Loi de $\hat{\sigma}^2$

- À des constantes près, revient à déterminer la loi de

$$\|Y - X\hat{B}\|^2 = \|\Pi_{E_X^\perp} Y\|^2$$

- Soit Π un projecteur orthogonal sur un sous-espace vectoriel de dimension l et U de loi $\mathcal{N}(0, I)$:

$$\triangleright \Pi U \sim \mathcal{N}(0, \underbrace{\Pi^t \Pi}_{\Pi})$$

$$\triangleright \Pi \text{ diagonalisable dans une B.O.N. : } C \Pi^t C = \begin{bmatrix} I_l & 0 \\ 0 & 0 \end{bmatrix} \text{ où}$$

seuls l ($= \text{rang}(\Pi) = n - p - 1$ ici) V_i sont non nuls p.s.

(ces V_i non nuls constituent un échantillon $\mathcal{N}(0, 1)$)

C : matrice d'isométrie. $C^t C = I$

$$V = C \Pi U \sim \mathcal{N}(0, C \Pi^t C) \quad \|\Pi U\|^2 = \|C \Pi U\|^2 = \sum_i V_i^2$$

$$\|\Pi U\|^2 \sim \chi_l^2$$

Loi de $\hat{\sigma}^2$: en un mot

- $\frac{n-p-1}{\sigma^2} \hat{\sigma}^2 \sim \chi^2_{n-p-1}$

Intervalles de confiance pour les β_i

- Si on arrive à établir la pertinence de la régression, alors on peut interpréter les paramètres.

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	52317.831	12237.362	4.275	0.00523	**
x1	27.641	5.429	5.091	0.00224	**
x2	12529.768	400.067	31.319	7.04e-08	***
x3	2553.211	530.669	4.811	0.00297	**
x4	-234.237	13.268	-17.654	2.12e-06	***

Residual standard error: 970.6 on 6 degrees of freedom

Multiple R-Squared: 0.9967, Adjusted R-squared: 0.9946

F-statistic: 459.8 on 4 and 6 DF, p-value: 1.372e-07

- Formule d'un intervalle de confiance pour β_1 au seuil 5%
- Valeur numérique
- Test de $H_0 : \langle \beta_1 = 0 \rangle$ contre $H_1 : \langle \beta_1 \neq 0 \rangle$ au seuil 5%
- Interprétation du résultat du test

• Cf. Exercice 1 et TP 1

- À faire par groupes de deux étudiants. Durée : 8 min.
- Rappel : cas i.i.d. gaussien

Expression des intervalles de confiance

Test d'hypothèses

- Test de $H_0 : \ll \beta_1 = 0 \gg$ contre $H_1 : \ll \beta_1 \neq 0 \gg$
- Rappel : $\frac{\hat{B}_1 - \beta_1}{\sqrt{\hat{\sigma}^2 ({}^t X X)_{22}^{-1}}} \sim st(n-p-1)$
- Par dualité entre intervalle de confiance et test, on sait déjà qu'on rejette H_0 au seuil 5%
- Région critique $W = \left\{ \frac{|\hat{B}_1|}{\sqrt{\hat{\sigma}^2 ({}^t X X)_{22}^{-1}}} > F_{st(n-p-1)}^{-1} \left(1 - \frac{\alpha}{2} \right) \right\}$
- On retrouve la p-valeur du test

$$2 \times \left(1 - F_{st(n-p-1)} \left(\frac{|\hat{B}_1|}{\sqrt{\hat{\sigma}^2 ({}^t X X)_{22}^{-1}}} \right) \right) \quad \left\{ \begin{array}{l} H_0 \quad Y = \cancel{\beta_1 x_1} + \dots + \beta_4 x_4 + \beta_0 + \varepsilon \\ H_1 \quad Y = \beta_1 x_1 + \dots + \beta_4 x_4 + \beta_0 + \varepsilon \end{array} \right.$$

• Ici 0,00224

Choix des régresseurs

- Cf. Exercice

Comprendre la formule de décomposition de la variance = Pythagore

- Version probabiliste (pas besoin de données !)

$$\underbrace{\text{var}(Y)}_{Y=f(X)+\varepsilon} = \underbrace{E[\text{var}(Y|X)]}_{\sigma^2} + \underbrace{\text{var}(E[Y|X])}_{\text{var}(f(X))}$$

- Version empirique (géométrie dans \mathbb{R}^n)

$$\frac{1}{n} \sum_i (y_i - \bar{y}_n)^2 = \frac{1}{n} \sum_i (\hat{\varepsilon}_i - \bar{\hat{\varepsilon}}_n)^2 + \frac{1}{n} \sum_i (\hat{Y}_i - \bar{\hat{Y}}_n)^2$$

variance
empirique des
observations s_y^2

variance
empirique des
résidus
empiriques

variance
empirique des
valeurs prédites $\hat{f}(x_i)$

• indépendante
du modèle de
régression choisi

• doit être
«relativement faible»
si la régression est
pertinente

• doit être
«relativement élevée»
si la régression est
pertinente
• liée à R_{xy}^2 : vaut $R_{xy}^2 s_y^2$

E.M.V. de β

- Fonction de vraisemblance :

$$\mathcal{L}_{y_1, \dots, y_n}(\beta, \sigma^2) = \prod_i f_{\mathcal{N}(\langle x_i; \beta \rangle, \sigma^2)}(y_i) \Rightarrow$$

y_1, \dots, y_n est « comme un échantillon gaussien d'espérance $\langle x_i; \beta \rangle$ »

$$\log \mathcal{L}_{y_1, \dots, y_n}(\beta, \sigma^2) = \sum_i \left\{ -\frac{1}{2} \log(2\pi \sigma^2) - \frac{(y_i - \langle x_i; \beta \rangle)^2}{(2\sigma^2)} \right\}$$

$y_i - \langle x_i; \hat{\beta} \rangle \hat{=} \varepsilon_i$

$$= -\frac{n}{2} \log(2\pi \sigma^2) - \frac{\|Y - X\beta\|^2}{(2\sigma^2)}$$

indépendant de β

maximum pour $\beta = \Pi_{EX}(Y)$

- Donc E.M.V. et E.M.C. de β coïncident dans le cas gaussien : même notation \hat{B}

- $\frac{\partial \mathcal{L}_{y_1, \dots, y_n}(\hat{B}, \sigma^2)}{\partial \sigma^2}$ est nulle en $\sigma^2 = \frac{1}{n} \|Y - X\hat{B}\|^2$

(estimateur biaisé, débiaisé en $\hat{\sigma}^2 = \frac{1}{n-p-1} \|Y - X\hat{B}\|^2$)

Efficacité de \hat{B}^2

- On montre que \hat{B} est un estimateur sans biais de β efficace

$$\nabla_{\beta} \log \mathcal{L}_{y_1, \dots, y_n}(\beta, \sigma^2) = -\frac{1}{2\sigma^2} \nabla_{\beta} \|Y - X\beta\|^2 = \frac{1}{\sigma^2} {}^t X (Y - X\beta)$$

de matrice de covariance $\frac{1}{\sigma^2} {}^t X X = \text{cov}(\hat{B})^{-1}$

- \hat{B} est donc l'estimateur sans biais de variance minimale de β

Coefficient de corrélation linéaire multiple

- Définition : $R = \sup_{(a_1, \dots, a_p) \in \mathbb{R}^p} R_{Y, \sum_j a_j X_j}$
- On se ramène à des régressions linéaires simples (en dimension 1)
- Propriété : $R^2 = \frac{S_{\hat{Y}}^2}{S_Y^2}$ - d'autant plus proche de 1 que la variance expliquée est proche de la variance totale (ratio de variance expliquée)

Test de pertinence de la régression multiple

- Test de $H_0 : \langle \beta_1 = \dots = \beta_p = 0 \rangle$ contre $H_1 : \langle \exists i \geq 1, \beta_i \neq 0 \rangle$

ne concerne pas β_0 qui n'est lié à aucun régresseur

- H_1 s'interprète comme : il y a au moins un facteur qui a un effet sur (l'espérance de) Y

- Région critique :

$$W = \left\{ \frac{n-p-1}{p} \frac{R^2}{1-R^2} > F_{\mathcal{F}(p, n-p-1)}^{-1}(1-\alpha) \right\}$$

- Preuve : cas particulier de test d'hypothèse linéaire

Qualité de la régression multiple

- Contexte :
 - valider un modèle de régression linéaire multiple
 - choisir les régresseurs

Quand on augmente le nombre de régresseurs

- le coefficient de corrélation linéaire multiple augmente forcément

oui	non	autres réponses
-----	-----	-----------------

- la p-valeur du test de pertinence de la régression diminue forcément

oui	non	autres réponses
-----	-----	-----------------

À faire par groupes de 2 étudiants.
Durée : 7 minutes

Illustration

A

Call:

```
lm(formula = y1 ~ x1)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-20.2786	7.6296	-2.658	0.01510	*
x1	1.9029	0.5809	3.276	0.00378	**

Residual standard error: 17.29 on 20 degrees of freedom

Multiple R-Squared: 0.3492

F-statistic: 10.73 on 1 and 20 DF, p-value: 0.003781

B

Call :

```
lm(formula = y1 ~ x1 + x2)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-19.4834	7.7985	-2.498	0.02182	*
x1	1.8830	0.5885	3.199	0.00472	**
x2	1.5596	2.1468	0.726	0.47641	

Residual standard error: 17.49 on 19 degrees of freedom

Multiple R-Squared: 0.3668

F-statistic: 5.502 on 2 and 19 DF, p-value: 0.01303

Script :

```
n <- 22
```

```
x1 <- seq(1,n)
```

```
x2 <- 2*rnorm(n)
```

```
y1 <- x1 + 1 + 20 * rnorm(n)
```

Devrait conduire, sauf accident
dû au hasard, à préférer le
modèle A au modèle B

Comparaison de l'effet des régresseurs

- Un statisticien, fumeur et buveur invétéré s'intéresse à un modèle de prévision de l'espérance de vie publié dans un journal médical :
$$Y = \beta_3 x_3 + \beta_2 x_2 + \beta_1 x_1 + \beta_0 + \underbrace{\varepsilon}_{\mathcal{N}(0, \sigma^2)}$$

où x_1 représente la consommation annuelle de graisses animales, x_2 la consommation de tabac, x_3 celle d'alcool et Y la durée de vie.
- Le journal donne : $\hat{\beta}_3 = -0.0018$, $\hat{\beta}_2 = -0.0008$, $\hat{\beta}_1 = -0.25$, $\hat{\beta}_0 = 79$

ans / l de bière

ans / paquet
de cigarette

ans / kg
- Cette personne est prête à réduire sa consommation de bière à 0,5 l / jour et à arrêter de fumer, ou de réduire sa consommation de cigarettes à 1 paquet / jour et à arrêter de boire, mais certainement pas les deux à la fois. À choisir, il préférerait arrêter de fumer.

Pour sa santé, que lui conseillez-vous d'arrêter ?

tabac	bière	autres réponses
-------	-------	-----------------

À faire par groupes de 2 étudiants.

Durée : 3 minutes

Modélisation

- En arrêtant de fumer, son espérance de vie moyenne estimée devient
$$365 \times (\underbrace{\hat{\beta}_3 \times 0,5 + \hat{\beta}_2 \times 0}_{-0.009} + \hat{\beta}_1 x_1) + \hat{\beta}_0$$
- En arrêtant de boire, elle devient
$$365 \times (\underbrace{\hat{\beta}_3 \times 0 + \hat{\beta}_2 \times 1}_{-0.008} + \hat{\beta}_1 x_1) + \hat{\beta}_0$$
 - Il semble qu'arrêter de boire soit une meilleure solution. Cependant même en simulant un modèle avec $0,5 \beta_3 = \beta_2 = -0,008$ on peut très bien obtenir $\hat{\beta}_3 = -0.0018, \hat{\beta}_2 = -0.0008$
 - Dans ce cas la personne arrêterait de boire plutôt que de fumer, contre ses préférences, ce qui serait désolant.

Il faut tester si $0,5 \beta_3 = \beta_2$

- Sous cette hypothèse :
$$\beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix} = \beta_0 \begin{pmatrix} 1 \\ 0 \\ 0 \\ 0 \end{pmatrix} + \beta_1 \begin{pmatrix} 0 \\ 1 \\ 0 \\ 0 \end{pmatrix} + \beta_2 \begin{pmatrix} 0 \\ 0 \\ 1 \\ 2 \end{pmatrix}$$
 est dans un sous-espace vectoriel ξ_0 de dimension 3 de \mathbb{R}^4

Pour sa santé, que lui conseillez-vous d'arrêter ?

Autres réponses (??)

Tests d'hypothèses linéaires

- Formulation générale : $H_0 : \langle \beta \in \xi_0 \rangle$ contre $H_1 : \langle \beta \notin \xi_0 \rangle$

- Construction du test : $\mathbb{R}^n = E_0 \oplus E_X^\perp \oplus E_X \cap E_0^\perp$

où $E_0 = \{X\beta \mid \beta \in \xi_0\}$

- Sous H_0 , $X\beta \in E_0 \Rightarrow \Pi_{E_X \cap E_0^\perp} X\beta = 0$

- Le test est basé sur la comparaison de

$$\|\Pi_{E_X \cap E_0^\perp} X\hat{B}\|^2 = \|\Pi_{E_X \cap E_0^\perp} Y\|^2 \quad \underbrace{\|\Pi_{E_X^\perp} Y\|^2}_{n \times \text{variance résiduelle}} \quad \text{et de}$$

(en fait le rapport des deux est une fonction

pivotal : statistique indépendante de β et σ^2)

- Il suffit de déterminer la loi du carré de la norme de projections orthogonales sur des sous-espaces orthogonaux

Théorème de Cochran

- Généralisation des théorèmes d'indépendance de $X \hat{B}$ et $Y - X \hat{B}$ et de la loi du χ^2 pour $\frac{1}{\sigma^2} \|Y - X \hat{B}\|^2$
- Hypothèses :
 - $\mathbb{R}^n = E_1 \oplus^\perp \dots \oplus^\perp E_r$, $\dim(E_i) = d_i$
 - $U \sim \mathcal{N}(0; \sigma^2 I)$
- Résultat : les $\frac{1}{\sigma^2} \|\Pi_{E_i} U\|^2$ sont des variables aléatoires indépendantes de loi $\chi_{d_i}^2$
- Corollaire : les rapports $\frac{d_j}{d_i} \frac{\|\Pi_{E_i} U\|^2}{\|\Pi_{E_j} U\|^2}$ sont de loi $\mathcal{F}(d_i, d_j)$

Retour aux tests d'hypothèses linéaires

- $\mathbb{R}^n = \underbrace{E_0}_{\dim: q} \oplus^\perp \underbrace{E_X^\perp}_{n-p-1} \oplus^\perp \underbrace{E_X \cap E_0^\perp}_{p+1-q}$ N.B. $\dim(E_0) = \dim(\{X\beta \mid \beta \in \xi_0\}) = \dim(\xi_0)$

- Sous H_0 , $\frac{n-p-1}{p+1-q} \frac{\|\Pi_{E_X \cap E_0^\perp} Y\|^2}{\|\Pi_{E_X^\perp} Y\|^2} \sim \mathcal{F}(p+1-q, n-p-1)$

- D'où la région critique

$$W = \left\{ \frac{n-p-1}{p+1-q} \frac{\|\Pi_{E_X \cap E_0^\perp} Y\|^2}{\|\Pi_{E_X^\perp} Y\|^2} > F_{\mathcal{F}(p+1-q, n-p-1)}^{-1}(1-\alpha) \right\}$$

- Cas particulier :
test de pertinence
de la régression

$$\xi_0 = \text{vect} \left(\left\{ \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \right\} \right)$$